Tucil 13520101 13520119

February 26, 2023

1 Tugas Kecil 1 IF3270

1.1 Eksplorasi Library Algoritma Pembelajaran pada Jupyter Notebook

1.1.1 Anggota

- 1. 13520101 Aira Thalca Avila Putra
- 2. 13520119 Marchotridyo

2 Bagian 1: Mengenal dataset breast-cancer

```
[1]: # Load data breast_cancer
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()
```

```
[2]:
       mean radius
                    mean texture
                                  mean perimeter mean area mean smoothness \
     0
              17.99
                            10.38
                                           122.80
                                                      1001.0
                                                                       0.11840
     1
              20.57
                            17.77
                                           132.90
                                                      1326.0
                                                                       0.08474
     2
              19.69
                            21.25
                                           130.00
                                                      1203.0
                                                                      0.10960
              11.42
     3
                            20.38
                                            77.58
                                                       386.1
                                                                       0.14250
              20.29
                            14.34
                                           135.10
                                                      1297.0
                                                                       0.10030
       mean compactness mean concavity mean concave points mean symmetry \
                 0.27760
                                  0.3001
                                                      0.14710
                                                                      0.2419
```

```
1
            0.07864
                              0.0869
                                                   0.07017
                                                                    0.1812
2
                              0.1974
                                                   0.12790
                                                                    0.2069
            0.15990
3
            0.28390
                              0.2414
                                                   0.10520
                                                                    0.2597
4
            0.13280
                              0.1980
                                                   0.10430
                                                                    0.1809
   mean fractal dimension ... worst texture worst perimeter worst area
0
                  0.07871
                                       17.33
                                                         184.60
                                                                     2019.0
1
                  0.05667
                                       23.41
                                                        158.80
                                                                     1956.0
2
                  0.05999
                                       25.53
                                                        152.50
                                                                     1709.0
3
                  0.09744
                                       26.50
                                                                      567.7
                                                         98.87
4
                  0.05883
                                       16.67
                                                        152.20
                                                                     1575.0
   worst smoothness worst compactness worst concavity worst concave points
0
             0.1622
                                 0.6656
                                                   0.7119
                                                                          0.2654
             0.1238
                                                   0.2416
                                                                          0.1860
1
                                 0.1866
2
             0.1444
                                 0.4245
                                                   0.4504
                                                                          0.2430
3
             0.2098
                                 0.8663
                                                   0.6869
                                                                          0.2575
4
             0.1374
                                 0.2050
                                                   0.4000
                                                                          0.1625
                   worst fractal dimension
   worst symmetry
0
           0.4601
                                    0.11890
1
           0.2750
                                    0.08902
                                                   0
2
           0.3613
                                    0.08758
                                                   0
3
           0.6638
                                    0.17300
                                                   0
4
           0.2364
                                    0.07678
                                                   0
```

[5 rows x 31 columns]

```
[3]: # Lihat data fitur apa saja yang dimiliki oleh dataset dan nama targetu variabelnya
print(data.feature_names)
print(data.target_names)
```

```
['mean radius' 'mean texture' 'mean perimeter' 'mean area'
'mean smoothness' 'mean compactness' 'mean concavity'
'mean concave points' 'mean symmetry' 'mean fractal dimension'
'radius error' 'texture error' 'perimeter error' 'area error'
'smoothness error' 'compactness error' 'concavity error'
'concave points error' 'symmetry error' 'fractal dimension error'
'worst radius' 'worst texture' 'worst perimeter' 'worst area'
'worst smoothness' 'worst compactness' 'worst concavity'
'worst concave points' 'worst symmetry' 'worst fractal dimension']
['malignant' 'benign']
```

Jadi, apa yang ingin dilakukan setelah melakukan pembelajaran? Yang nantinya ingin dilakukan: Dari suatu data (yang berisikan nilai dari feature 'mean radius' s.d. 'worst fractal dimension') yang diberikan, kita ingin mengklasifikasikan data tersebut apakah bersifat 'malignant'

(0) atau 'benign' (1).

Sebelum dimulai learning, cek beberapa informasi tambahan dahulu...

[4]: dataset.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 31 columns):

#	Column	Non-Null Count	Dtype
0	mean radius	569 non-null	float64
1	mean texture	569 non-null	float64
2	mean perimeter	569 non-null	float64
3	mean area	569 non-null	float64
4	mean smoothness	569 non-null	float64
5	mean compactness	569 non-null	float64
6	mean concavity	569 non-null	float64
7	mean concave points	569 non-null	float64
8	mean symmetry	569 non-null	float64
9	mean fractal dimension	569 non-null	float64
10	radius error	569 non-null	float64
11	texture error	569 non-null	float64
12	perimeter error	569 non-null	float64
13	area error	569 non-null	float64
14	smoothness error	569 non-null	float64
15	compactness error	569 non-null	float64
16	concavity error	569 non-null	float64
17	concave points error	569 non-null	float64
18	symmetry error	569 non-null	float64
19	fractal dimension error	569 non-null	float64
20	worst radius	569 non-null	float64
21	worst texture	569 non-null	float64
22	worst perimeter	569 non-null	float64
23	worst area	569 non-null	float64
24	worst smoothness	569 non-null	float64
25	worst compactness	569 non-null	float64
26	worst concavity	569 non-null	float64
27	worst concave points	569 non-null	float64
28	worst symmetry	569 non-null	float64
29	worst fractal dimension	569 non-null	float64
30	target	569 non-null	int32
	67 .04(00)00(4)		

dtypes: float64(30), int32(1)

memory usage: 135.7 KB

Beberapa hal yang bisa diperhatikan dari pemanggilan df.info():

- 1. Tidak ada missing values, dan
- 2. Semua tipe datanya numerik

3 Bagian 2: Membagi dataset menjadi 80% data training dan 20% data testing

```
[5]: from sklearn.model_selection import train_test_split

X = data.data
Y = data.target

# Bagi menjadi 80% data training dan 20% data testing
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.20)
```

4 Bagian 3: Melakukan pembelajaran untuk membentuk classifier dengan berbagai algoritma

4.1 Decision Tree

```
|--- mean concave points <= 0.05
   |--- worst area <= 957.45
       |--- worst symmetry <= 0.16
           |--- class: 0
       |--- worst symmetry > 0.16
           |--- worst perimeter <= 108.25
               |--- smoothness error <= 0.00
                   |--- worst concave points <= 0.10
                       |--- class: 1
                   |--- worst concave points > 0.10
                       |--- class: 0
               |--- smoothness error > 0.00
                   |--- worst texture <= 33.35
                       |--- class: 1
                  |--- worst texture > 33.35
                       |--- mean texture <= 23.20
                           |--- class: 0
                       |--- mean texture > 23.20
                           |--- class: 1
           |--- worst perimeter > 108.25
               |--- worst smoothness <= 0.14
               | |--- texture error <= 1.48
```

```
| | |--- class: 1
                 |--- texture error > 1.48
                  | |--- class: 0
              |--- worst smoothness > 0.14
              | |--- class: 0
   |--- worst area > 957.45
       |--- worst fractal dimension <= 0.06
       | |--- class: 1
       |--- worst fractal dimension > 0.06
       | |--- class: 0
|--- mean concave points > 0.05
   |--- worst concavity <= 0.23
       |--- mean radius <= 16.59
       | |--- class: 1
       |--- mean radius > 16.59
       | |--- class: 0
   |--- worst concavity > 0.23
       |--- mean radius <= 11.18
          |--- class: 1
       |--- mean radius > 11.18
         |--- mean texture <= 15.38
              |--- worst perimeter <= 119.55
             | |--- class: 1
             |--- worst perimeter > 119.55
           | | |--- class: 0
         |--- mean texture > 15.38
             |--- fractal dimension error <= 0.01
             | |--- class: 0
              |--- fractal dimension error > 0.01
              | |--- class: 1
```

4.2 ID3

```
[7]: import six
import sys
sys.modules['sklearn.externals.six'] = six

from id3 import Id3Estimator

id3Classifier = Id3Estimator()
id3Classifier = id3Classifier.fit(X_train, Y_train)
```

4.3 K-Means

```
[8]: from sklearn.cluster import KMeans
kMeansClassifier = KMeans(n_clusters = 2, n_init = 10)
kMeansClassifier = kMeansClassifier.fit(X_train)
```

4.4 Logistic Regression

```
C:\Python310\lib\site-packages\sklearn\linear_model\_logistic.py:458:
ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

Increase the number of iterations (max_iter) or scale the data as shown in:
 https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:

 $\verb|https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression| \\$

n_iter_i = _check_optimize_result(

4.5 Neural Network

```
[10]: from sklearn.neural_network import MLPClassifier
mlpClassifier = MLPClassifier(hidden_layer_sizes=(100, 100, 100), max_iter=1000)
mlpClassifier.fit(X_train, Y_train)
```

[10]: MLPClassifier(hidden_layer_sizes=(100, 100, 100), max_iter=1000)

4.6 SVM

```
[11]: from sklearn.svm import SVC

svmClassifier = SVC(C=100, kernel='linear')
svmClassifier.fit(X_train, Y_train)
```

[11]: SVC(C=100, kernel='linear')

5 Bagian 4: Menyimpan model hasil pembelajaran

```
[12]: import pickle
pickle.dump(decisionTreeClassifier, open("decisionTreeClassifier.sav", "wb"))
```

6 Bagian 5: Melakukan prediksi dengan loaded model

6.1 Set up

```
[13]: from sklearn.metrics import accuracy_score, precision_score, recall_score,
       def predictFromModel(modelFileName):
       loadedModel = pickle.load(open(modelFileName, "rb"))
       modelName = modelFileName.rstrip(".sav")
       # Lakukan prediksi
       Y_pred = loadedModel.predict(X_test)
       accuracy = accuracy_score(Y_test, Y_pred)
       precision = precision_score(Y_test, Y_pred)
       recall = recall_score(Y_test, Y_pred)
       f1 = f1_score(Y_test, Y_pred)
       cmat = confusion_matrix(Y_test, Y_pred)
       print(f'''Hasil prediksi dari model {modelName}:
       Accuracy: {accuracy}
       Precision: {precision}
       Recall: {recall}
       F1: {f1}
       Confusion matrix:
       {cmat}
        111)
```

6.2 Decision Tree

```
[14]: predictFromModel("decisionTreeClassifier.sav")
```

Hasil prediksi dari model decisionTreeClassifier:

Accuracy: 0.8947368421052632

Precision: 0.92 Recall: 0.92 F1: 0.92

```
[[33 6]
      [ 6 69]]
     6.3 ID3
[15]: predictFromModel("id3Classifier.sav")
     Hasil prediksi dari model id3Classifier:
       Accuracy: 0.9035087719298246
       Precision: 0.9324324324325
       Recall: 0.92
       F1: 0.9261744966442953
       Confusion matrix:
       [[34 5]
      [ 6 69]]
     6.4 K-Means
[16]: predictFromModel("kMeansClassifier.sav")
     Hasil prediksi dari model kMeansClassifier:
       Accuracy: 0.15789473684210525
       Precision: 0.0
       Recall: 0.0
       F1: 0.0
       Confusion matrix:
       [[18 21]
      [75 0]]
     6.5 Logistic Regression
[17]: predictFromModel("logisticRegressionClassifier.sav")
     Hasil prediksi dari model logisticRegressionClassifier:
       Accuracy: 0.9649122807017544
       Precision: 0.961038961038961
       Recall: 0.986666666666667
```

Confusion matrix:

F1: 0.9736842105263157

```
Confusion matrix: [[36 3] [ 1 74]]
```

6.6 Neural Network

```
[18]: predictFromModel("mlpClassifier.sav")

Hasil prediksi dari model mlpClassifier:
```

Accuracy: 0.9035087719298246
Precision: 0.9102564102564102
Recall: 0.946666666666667
F1: 0.9281045751633987

Confusion matrix:
[[32 7]
[4 71]]

6.7 SVM

[1 74]]

```
[19]: predictFromModel("svmClassifier.sav")
```

Hasil prediksi dari model svmClassifier:

Accuracy: 0.9649122807017544
Precision: 0.961038961038961
Recall: 0.986666666666667
F1: 0.9736842105263157

Confusion matrix:
[[36 3]

7 Bagian 6: Analisis hasil metrik evaluasi

Dari beberapa model yang sudah dibuat dan diuji, didapatkan hasil bahwa: 1. Skor accuracy tertinggi didapatkan oleh model Logistic Regression 2. Skor precision tertinggi didapatkan oleh model Logistic Regression 3. Skor recall tertinggi didapatkan oleh model K-Means 4. Skor F1 tertinggi didapatkan oleh model Logistic Regression

Secara umum, seluruh model yang dibuat memiliki skor yang cukup baik. Namun, ada beberapa hal yang perlu diperhatikan: - Skor accuracy yang didapatkan oleh model K-Means adalah satusatunya yang memiliki skor dibawah 0.9. Hal ini bisa disebabkan karena model K-Means memiliki

skor yang rendah jika ia mengklasifikasikan kelasnya salah (misal, yang seharusnya targetnya 0 dia klasifikasikan menjadi 1). - Model paling cocok yang digunakan adalah model Logistic Regression, karena memiliki skor yang paling tinggi di semua metrik evaluasi. Hal ini bisa disebabkan karena model Logistic Regression cocok digunakan untuk klasifikasi biner (mengklasifikasikan suatu data menjadi dua kelas, yaitu 0 dan 1). Tipe data yang digunakan juga cocok digunakan untuk model Logistic Regression, yaitu data numerik. - Model SVM dengan kernel linear dan Decision Tree juga cocok untuk digunakan sebagai model karena keduanya cocok digunakan untuk klasifikasi biner. Selain itu, model SVM cocok digunakan untuk data yang memiliki banyak feature.

8 Bagian 7: K-Fold Cross Validation pada DecisionTreeClassifier

Data 10-fold cross validation:

Accuracy: [0.9122807 0.84210526 0.9122807 0.85964912 0.96491228 0.9122807 0.9122807 0.94736842 0.92982456 0.98214286], with mean 0.9175125313283209 F1: [0.92957746 0.87323944 0.93150685 0.88571429 0.97222222 0.93150685 0.93506494 0.95774648 0.94117647 0.98591549], with mean 0.9343670485459251

Average accuracy: 0.9175125313283209 Average f1: 0.9343670485459251

8.1 Perbandingan dengan skor prediksi DecisionTreeClassifier sebelumnya

Dapat dilihat bahwa menurut akurasi antara K-Fold Cross Validation dan prediksi Decision-TreeClassifier sebelumnya, kedua skor tersebut hampir sama. Hal ini bisa disebabkan karena jumlah data yang digunakan untuk melakukan K-Fold Cross Validation adalah 80% dari data yang ada, sehingga jumlah data yang digunakan untuk melakukan K-Fold Cross Validation hampir sama dengan jumlah data yang digunakan untuk melakukan prediksi DecisionTreeClassifier sebelumnya. Dalam beberapa percobaa, nilai akurasi yang didapatkan dari K-Fold Cross Validation kadang lebih baik dan kadang lebih buruk dari prediksi DecisionTreeClassifier sebelumnya. Secara keseluruhan, K-Fold Cross Validation memberikan gambaran yang baik mengenai performa model, dalam hal ini DecisionTreeClassifier.